



ARTICLE DE RECHERCHE

Article Info.:

Reçu : le 27/01/2025

Accepté : le 10/03/2025

Publié : le 06/05/2025

CLASSIFICATION NON SUPERVISÉ FLOU BASÉ AVEC RÉGULARISATION DANS LA FONCTION COUT POUR LA SEGMENTATION DU SYNDROME MÉTABOLIQUE

Pierre Katalay Kafunda ^{1,*}, Félicien Jordan Masakuna ¹

<https://doi.org/10.70237/jafrisci.2025.v2.i1.05>

Resumé

Le Fuzzi C-Means est un algorithme d'apprentissage non supervisé qui a pour objectif de créer des classes floues à partir d'une population hétérogène. Dans le cadre flou, les classes obtenues forment un recouvrement et non une partition comme dans le cas déterministe où les variables sont connues avec certitude. Dans cet article, notre objectif est de créer un sof computing qui traite les données caractérisées par l'imprécision, l'incertitude. Il est utilisé en intelligence artificielle pour implémenter de solution de calcul inexactes, pour lesquels une solution exacte ne peut être dérivée en temps polynomial. On va se servir de cette approche pour segmenter les données de type flou. Notre approche basée sur l'agglomération compétitive permet d'améliorer le Fuzzi C-Means (FCM) et le C-Means possibiliste dont au démarrage il faut fixer à priori le nombre de classes, ce qui n'est pas le cas pour notre approche. Nous avons introduit une composante de régularisation dans la fonction cout, permettant de ne pas fixer à priori le nombre de groupes.

Mots clés : Logique floue, Fuzzification, Defuzzification, Apprentissage Automatique, Classification automatique non supervisé, Syndrome métabolique

Abstract

Fuzzi C-Means is an unsupervised learning algorithm which aims to create fuzzy classes from a heterogeneous population. In the fuzzy framework, the classes obtained form an overlap and not a partition as in the deterministic case where the variables are known with certainty. In this article, our objective is to create a sof computing which processes data characterized by imprecision, uncertainty. It is used in artificial intelligence to implement inexact computational solutions, for which an exact solution cannot be derived in polynomial time. We will use this approach to segment fuzzy data. Our approach based on competitive agglomeration makes it possible to improve the Fuzzi C-Means (FCM) and the possibilistic C-Means, for which at start-up the number of classes must be fixed a priori, which is not the case for our approach. . We introduced a regularization component into the cost function, making it possible to not fix the number of groups a priori.

Key words : Fuzzy logic, Fuzzification, Defuzzification, Machine Learning, Unsupervised automatic classification, Metabolic syndrome.

INTRODUCTION

Le syndrome métabolique constitue actuellement un fléau pour l'humanité et le nombre de personnes atteint de cette maladie ne fait qu'augmenter de manière exponentielle. Aux Etats Unis d'Amérique par exemple, plusieurs personnes sont victimes de Syndrome métabolique. En Afrique, le diabète est devenu de plus en plus fréquent, 12 millions des personnes atteintes (en 2010) [OMS, IDF, 2010]. L'objectif principal de cet article consiste à mettre en place, un système flou intelligent appelé sof computing basé sur la classification non supervisée floue, pour la segmentation du syndrome métabolique en utilisant une nouvelle approche appelée agglomération compétitive qui permet de créer des classes floues sans fixer au préalable le

nombre de classes. Ce soft computing est un outil d'aide pour le renforcement de diagnostic du syndrome métabolique.

Dans cet article, nous nous intéressons aux données complexes ou floues. Il peut arriver que les données ne soient pas spécifiées correctement ou non mesurables avec exactitude ou difficilement quantifiables numériquement. Les attributs sont alors des variables linguistiques, dont les valeurs sont construites avec des adjectifs et des adverbes du langage courant : grand, petit, très, un peu, etc. Ainsi les valeurs de l'univers de discours qui sont des valeurs réelles, seront remplacées par un ensemble de "labels" flous se recouvrant, comme par exemple {très petit, petit, moyen, grand, très grand}, et toute mesure numérique, sera convertie sur cette

échelle.

Un sous ensemble flou défini dans un univers de discours sera caractérisé par sa fonction d'appartenance, qui est une application définie de l'univers de discours à valeur dans l'intervalle $[0,1]$

Notre problème se présente de la manière suivante :

Considérons un ensemble fini d'individus caractérisés par p variables de type floues, segmenter X en k classes $C_j, j = 1, \dots, k$ et les C_j forment un recouvrement de X . c'est-à-dire un même individu peut appartenir à au moins une classes, avec les degrés d'appartenance différents tel que $\sum_{j=1}^k \mu_{ij} = 1$, où μ_{ij} est le degré d'appartenance de l'individu i à la classe j .

Notre problématique est donc définie de la manière suivante :

Comment segmenter une population hétérogène en des classes homogènes dans un environnement flou.

Nous pensons que l'exploitation de la logique floue combinée avec les méthodes d'apprentissage automatique permettra d'obtenir une partition optimale.

Pour atteindre notre objectif nous allons utiliser l'apprentissage non supervisé flou basé sur l'agglomération compétitive.

La théorie de sous ensemble flous et les outils de raisonnement qu'en découlent, proposent un cadre formel qui permet de modéliser le langage naturel et de gérer l'imprécis (qui n'est pas exactement déterminé) et l'incertain (peu sûr).

Etant donné un ensemble X d'individus caractérisé par p variables floue, pour segmenter X en k classes floues. Pour y arriver, nous allons construire un système flou constitué de trois modules : *Fuzzification*, *Inférence floue*, *Défuzzification*.

La méthodologie utilisée se présente de ma manière suivante :

- ✓ Fuzzification de data set
- ✓ Utilisation de l'inférence floue de type Mandani
- ✓ Utilisation des algorithmes de l'apprentissage non supervisé flou
- ✓ Défuzzification et obtention de la partition optimale.

Notre article est organisé en trois sections :

- I. Théorie des sous-ensembles flous
- II. Classification non supervisé dans un environnement incertain
- III. Expérimentation et interprétation de résultats

I. THÉORIE DES SOUS-ENSEMBLES FLOUS

Dans cette section, nous introduisons les notions de sous ensemble flou, les opérateurs flous utilisés dans le modèle d'apprentissage non supervisé.

I.1. Définition.

Un sous-ensemble flou A d'un ensemble de référence U est caractérisé par une fonction d'appartenance $\mu: U \rightarrow [0,1]$. Pour un élément $x \in U$, $\mu(x)$ représente le degré d'appartenance de x à A .

$$\mu_A: U \rightarrow [0,1]$$

$$x \rightsquigarrow \mu_A(x)$$

$A = \{(x, \mu_A(x)): x \in E\}$; $\mu_A(x)$ est le degré d'appartenance de $x \in U$ au sous ensemble flou A et U est appelé univers de discours.

La figure suivante donne une illustration schématique de la notion de sous ensemble flou.




Figure 1. Illustration d'un sous ensemble A dans l'univers de discours U

I.2. Opérateurs logiques flous.

Le tableau ci-dessous donne quelques opérateurs flous souvent utilisés. On a ici, les opérateurs de Zadeh et les opérateurs probabilistes.

Tableau 1 : opérateurs flous

	Intersection (ou t-norme)	Réunion (t-conorme)	Complément
Opérateurs de Zadeh	$\mu_{A \cap B}(x) = \min(\mu_A, \mu_B)$	$\mu_{A \cup B}(x) = \max(\mu_A, \mu_B)$	$\mu_{\bar{A}}(x) = 1 - \mu_A(x)$
Opérateurs probabilistes	$\mu_{A \cap B}(x) = \mu_A(x) \cdot \mu_B(x)$	$\mu_{A \cup B} = \mu_A(x) + \mu_B(x) - \mu_A(x) \cdot \mu_B(x)$	$\mu_{\bar{A}}(x) = 1 - \mu_A(x)$

I.3. Structure interne d'un système flou (Oskouei, A.G., Samadi, N., Tanha, J., Bouyer, A. (2024).)

constituée de trois Modules : Fuzzification, Inférence floue et Défuzzification tel que présenté par la figure 2 ci-dessous :

Le fonctionnement d'un système flou repose sur une structure




Figure 2. Architecture d'un système flou

I.3.1. Définition (H. Verma et al. (2021))

Un système flou $F_{\mathcal{R}}$ est une application $F_{\mathcal{R}}: X \rightarrow Y$ où $X \subseteq \mathbb{R}^n$ et $Y \subseteq \mathbb{R}^m$ sont appelés respectivement domaine (ou espace d'entrées) et co-domaine (ou espace de sorties). $\mathcal{R}$ est une base de règle floues qui détermine la structure du système flou. $\mathcal{R} = \{R_1, \dots, R_r\}$ telle que chaque règle $R_k \in \mathcal{R}$ est un tuple d'ensemble flou. $R_k = (\mu_k^{(1)}, \dots, \mu_k^{(n)}, V_k^{(1)}, \dots, V_k^{(m)})$ où $\mu_k^{(i)}: X_i \rightarrow [0, 1]$ est un ensemble flou des variables d'entrée x_i et $V_k^{(j)}: Y_j \rightarrow [0, 1]$ est un ensemble flou pour les variables de sortie y_j

$$y_j = \text{defuzz} \left(\bigcup_{R_k \in \mathcal{R}} \{ \tilde{v}_k^{(j)} \} \right) \quad (1)$$

$$\tilde{v}_k^{(j)}: Y_j \rightarrow [0, 1], \quad y_j \rightarrow \tau_k \left\{ \tau_k, v_k^{(j)} \right\} \quad \text{avec} \quad \tau_k = \tau_1 \left\{ \mu_k^{(1)}(x_1), \dots, \mu_k^{(n)} \right\} \quad (2)$$

Détaillons les trois composantes d'un système flou :

I.3.1.1. Fuzzification

Elle consiste à associer à chaque valeur d'entrée un ou plusieurs sous-ensembles flous ainsi que les degrés d'appartenance associés. Cette étape réalise la transformation de valeurs numériques en informations symboliques floues. [Shukla, A.K., Behera, S.K., Basumatary, A., Shukla, V. (2024)]

I.3.1.2. Inférence floue

La phase d'inférence consiste à calculer le degré de vérité des différentes règles du système, en utilisant les formules données dans la phase de fuzzification, et à associer à chaque règle une valeur de sortie. Cette valeur de sortie dépend de la partie conclusion des règles qui peut prendre plusieurs formes. Donc

on peut dire que l'inférence floue est l'opération d'agrégation des règles floues. (Ma, Q., Zhu, X., Zhao, X., Fu, G., Zhang, R. 2024).

On distingue:

- ✓ **Système floue de Mandani** : Dans ce type de systèmes flous, la prémisse et la conclusion sont floues. Après la réalisation de l'inférence floue. Une étape de défuzzification est obligatoire pour le passage du symbolique au numérique.
- ✓ **Système floue de Takagi-Sugeno** : Dans ce type de Système d'Inférence Floue (SIF), la conclusion correspond à une constante ou une expression polynomiale. Il permet d'obtenir directement la sortie défuzzifiée à partir des règles linguistiques.

I.3.1.3. Déffuzzification

Par cette étape se fait le retour aux grandeurs de sortie réelles. Il s'agit de calculer, à partir des degrés d'appartenance à tous les ensembles flous de la variable de sortie, l'abscisse correspondant à la valeur de cette sortie. Il existe plusieurs méthodes pour calculer la valeur représentative d'un ensemble de sortie, dont les principales sont : Defuzzifications basées sur le centre de gravité des ensembles ; le MIN / MAX ; le SOM / PROD.

La classification non supervisée appelée aussi segmentation de données, dans le cas classique (ou dans un environnement déterministe), consiste à partitionner une population hétérogène $X = \{x_i \in R^p, 1 \leq i \leq n\}$ en des sous classes homogènes $C_j, j = 1, \dots, k$ de manière à minimiser l'inertie intra classe et à maximiser l'inertie interclasse (Ros, F., Riad, R.A. 2024)

La partition formée dans le cas déterministe :

1. $C_j \neq \emptyset$, pour $j = 1, \dots, k$
2. $C_i \cap C_j = \emptyset$, pour $i \neq j$
3. $\bigcup_{j=1}^k C_j = X$

La propriété (2) n'est pas valide pour le cas de la segmentation floue. Dans la classification non supervisée floue, un même individu peut appartenir à plusieurs classes floues avec les degrés d'appartenance différents tel que la somme de ces degrés d'appartenance soit égale à un.

Dans le cas déterministe, pour que les classes soient homogènes, on doit minimiser l'inertie intra classe et maximiser l'inertie interclasse d'où le théorème de Huygens suivant qui stipule que : l'inertie totale du nuage vaut la somme de l'inertie intra classe et l'inertie interclasse.

Théorème de Huyghens (Kaur, A., Kumar, Y., Sidhu, J. 2024)

$$I_t = I_{intra} + I_{inter}$$

Avec :

$$I_{intra} = \sum_{j=1}^k \sum_{i=1}^{n_j} p_j d^2(x_i, g_j) \quad (1)$$

$$I_{inter} = \sum_{j=1}^k p_j d^2(g_j, \bar{g}) \quad (2)$$

I_{intra} : Inertie intra classe

I_{inter} : Inertie interclasse

p_j : le poids de la classe j

Dans la partie suivante nous allons aborder les méthodes de la classification non supervisée floue.

II. CLASSIFICATION NON SUPERVISÉ DANS UN ENVIRONNEMENT INCERTAIN

Les ensembles flous jouent un rôle fondamental sur les techniques de classification automatique, la fonction à minimiser appelée inertie intra-classe est améliorée par l'insertion de niveau de fuzzification et le degré d'appartenance (Oskouei, A.G., Samadi, N., Tanha, J., Bouyer, A. (2024), Sahoo, R.C., Kumar, T., Tanwar, P., Pruthi, J., Singh, S. (2024)).

II.1. Fuzzi C-Means

L'algorithme des c-moyennes floues effectue une optimisation itérative en évaluant de façon approximative les minimums d'une fonction d'erreur (S. Askari, 2021, M. Shi et al. (2020)). Il existe toute une famille de fonctions d'erreur associées à cet algorithme qui se distinguent par des valeurs différentes prises par un paramètre réglable, m , appelé indice de flou (*fuzzy index*) et qui détermine le degré de flou de la partition obtenue ($m > 1$). Les degrés d'appartenance sont proches pour $m > 20$. Si m tend vers 1 on obtient une partition stricte. C'est pourquoi nous choisirons m entre 1 et 2. (Zhang, Y., Li, Y., Che, J. 2024)

Soit $X = \{x_i \in \mathbb{R}^p, 1 \leq i \leq n\}$ un ensemble d'individus, tel que chaque individu est caractérisé par p variables, dans un environnement incertain ou flou. L'environnement étant flou, nous allons définir le degré d'appartenance de chaque individu par rapport aux différents sous-ensembles flous.

Dans le cas de la classification non supervisée floue, nous cherchons à segmenter X en K classes $C_j, j = 1, \dots, k$ tel que les C_j forment soit une partition ou un recouvrement de X car un même individu peut appartenir à au moins deux classes avec les degrés d'appartenance différents et de telle sorte que la somme de ces degrés d'appartenance soit égal à un. Pour

atteindre cet objectif, nous avons d'abord défini notre univers de discours, les variables linguistiques ainsi que les attributs associés à ces variables linguistiques. Le fuzzy clustering est une approche de la classification non supervisée qui consiste à minimiser un critère fonctionnel qui s'écrit de la manière suivante (Wan, F., Wang, T., Fondrevelle, J., Duclos, A. 2024, Chan, K.Y., Yiu, K.F.C., Kim, D., Abu-Siada, A. 2024)

$$J(U, G, X) = \sum_{j=1}^k \sum_{i=1}^{n_j} (\mu_{ji})^m d^2(x_i, g_j) \quad (3)$$

g_j : est le centre de gravité de la classe j

μ_{ji} : est le degré d'appartenance de l'individu i à la classe j

U

$= (\mu_{ji})$ est la matrice de degré d'appartenance. Elle est de dimension $n \times k$ où n est le nombre d'individus et k est le nombre de classes.

L'algorithme FCM proposé par Bezdek repose sur la minimisation de la fonction objective, $J(U, G, X) = \sum_{j=1}^k \sum_{i=1}^{n_j} (\mu_{ji})^m d^2(x_i, g_j)$ sous contrainte $\sum_{j=1}^k \mu_{ji} = 1$

II.1.2. Construction de l'algorithme FCM (Bhimavarapu, U., Chintalapudi, N., Battineni, G. (2024), Chan, K.Y., Yiu, K.F.C., Kim, D., Abu-Siada, A. 2024, H. Verma et al. (2021)).

La construction de l'algorithme FCM repose sur l'optimisation d'une fonction quadratique avec contraintes sous forme d'égalité.

Considérons le programme mathématique suivant :

$$\begin{cases} \text{Min } J(U, G, X) = \sum_{j=1}^k \sum_{i=1}^{n_j} (\mu_{ji})^m d^2(x_i, g_j) \\ S/C \sum_{j=1}^k \mu_{ji} = 1 \end{cases} \quad (4)$$

Utilisons le lagrangien pour déterminer les paramètres du modèle.

$$L(\lambda, \mu_{ji}, g_j) = \sum_{j=1}^k \sum_{i=1}^{n_j} (\mu_{ji})^m d^2(x_i, g_j) - \lambda (\sum_{j=1}^k \mu_{ji} - 1) \quad (5)$$

$L(\lambda, \mu_{ji}, g_j)$ étant convexe (car la matrice de Hesse associée à L a toutes ses valeurs propres positives), les conditions de premier ordre sont suffisantes pour assurer l'optimalité. D'où (λ, μ_{ji}, g_j) est un point critique si et seulement si :

$$\begin{cases} \frac{\partial L}{\partial \mu_{ji}} = 0 \\ \frac{\partial L}{\partial \lambda} = 0 \\ \frac{\partial L}{\partial g_j} = 0 \end{cases}$$

$$\frac{\partial L}{\partial \lambda} = -(\sum_{j=1}^c \mu_{ji} - 1) = 0 \text{ et } \frac{\partial L}{\partial \mu_{ji}} = m \mu_{ji}^{m-1} d^2(x_i, g_j) - \lambda = 0, \text{ pour } j = 1, 2, \dots, c$$

A partir de cette égalité nous tirons :

$$\mu_{ji} = \left(\frac{\lambda}{m d^2(x_i, g_j)} \right)^{\frac{1}{m-1}} \quad (6)$$

A partir de la contrainte $\sum_{j=1}^c \mu_{ji} = 1$ nous avons

$$\sum_{j=1}^c \left[\lambda \left(\frac{1}{m d^2(x_i, g_j)} \right)^{\frac{1}{m-1}} \right] = 1$$

$$\lambda \sum_{j=1}^c \left(\frac{1}{m d^2(x_i, g_j)} \right)^{\frac{1}{m-1}} = 1$$

$$\lambda = \left[\sum_{j=1}^c \left(\frac{1}{m d^2(x_i, g_j)} \right)^{\frac{1}{m-1}} \right]^{-1} \quad (7)$$

Nous remplaçons λ dans l'expression (6) et on a :

$$\mu_{ji} = \left[\sum_{j=1}^c \left(\frac{1}{md^2(x_i, g_j)} \right)^{\frac{1}{m-1}} \right]^{-1} \left(\frac{1}{md^2(x_i, g_j)} \right)^{\frac{1}{m-1}}$$

$$\mu_{ji} = \frac{\left(\frac{1}{d^2(x^i, g_j)} \right)^{\frac{2}{m-1}}}{\sum_{c=1}^k \left(\frac{1}{d^2(x^i, g_c)} \right)^{\frac{2}{m-1}}} \quad (8)$$

Pour minimiser la fonction objective J, la dérivée partielle par rapport au centre de gravité doit être nulle :

$$\frac{\partial L}{\partial g_j} = 0 \quad \forall j = 1, 2, \dots, c$$

$$g_j = \frac{\sum_{i=1}^n (\mu_{ji})^m x_i}{\sum_{i=1}^n (\mu_{ji})^m} \quad (9)$$

L'algorithme des FCM est un algorithme d'apprentissage non supervisé dont les étapes sont les suivantes :

Etape 1 : Initialisation

Fixer un nombre de cluster c , et une matrice de degré d'appartenance $A = [\mu_{ji}]$. Cette matrice représente une partition floue des données, et doit vérifier la condition de normalisation

$$\sum_{j=1}^c u_{ji} = 1, \quad \forall i$$

Etape 2 : calculer le centre de gravité des classes :

$$g_j = \frac{\sum_{i=1}^n (\mu_{ji})^m x_i}{\sum_{i=1}^n (\mu_{ji})^m}$$

Etape 3 : Mise à jour de la matrice de degré d'appartenance suivant la position des centres de gravité :

$$\mu_{ji} = \frac{\left(\frac{1}{d^2(x^i, v_j)} \right)^{\frac{1}{m-1}}}{\sum_{j=1}^c \left(\frac{1}{d^2(x^i, v_j)} \right)^{\frac{1}{m-1}}}$$

II.1.3. L'algorithme FCM (Chan, K.Y., Yiu, K.F.C., Kim, D., Abu-Siada, A. 2024)

L'algorithme des FCM est un algorithme de classification non supervisé, il est itératif, et dont les étapes sont les suivantes :

Début

1. Initialisation :

Fixer arbitrairement un nombre de classes k , et une matrice d'appartenance $U = [\mu_{jk}]$. Cette matrice représente une partition floue des données, et doit vérifier la condition de normalisation $\sum_{j=1}^k u_{ji} = 1, \forall i$

2. Calcul des centres de gravité des classes :

$$g_j = \frac{\sum_{i=1}^n (\mu_{ji})^m x_i}{\sum_{i=1}^n (\mu_{ji})^m}$$

3. Mise à jour de la matrice de degré d'appartenance :

$$\mu_{ji} = \frac{\left(\frac{1}{d^2(x^i, g_j)} \right)^{\frac{2}{m-1}}}{\sum_{c=1}^k \left(\frac{1}{d^2(x^i, g_c)} \right)^{\frac{2}{m-1}}}$$

4. Critère d'arrêt :

$\|U^{t+1} - U^t\| < \epsilon$ alors Fin, sinon retourner à l'étape 2
 $\| \cdot \|$ désigne la norme matricielle, et ϵ est un réel positif

nous proposons l'algorithme suivant pour déterminer U^0 qui est la matrice de degré d'appartenance initiale :

Algo Matriflou_init

Début

Var nClasse, nLigne : Entier

Var matriceFlou(nClasse, nLigne) : Réel

Var nombre, nombreGenere : Réel

Pour j allant de 1 à n Ligne // indice de colonnes

Nombre $\leftarrow 1$ // variable contenant la valeur limite à générer

Pour i allant de 1 à n Classe // indice de lignes

nombreGenere $\leftarrow$ ValeurAleatoire(0, nombre) //

Valeur aléatoire générée entre 0 et nombre.

matriceFlou(i, j) $\leftarrow$ nombreGenere

nombre $\leftarrow$ nombre - nombreGenere

i suivant

j suivant

Fin

II.2. Méthode possibiliste.

Cette approche a été développée pour résoudre les problèmes des points équidistants de deux centres de gravité de deux classes différentes. Avec l'approche fuzzy c-means, ces points auront le même degré d'appartenance à ces deux classes, ce qui n'est pas correcte. Pour résoudre cette difficulté, Krishnapuram a proposé le c-moyennes possibiliste qui consiste à perturber la fonction économique en éliminant la contrainte de normalité. On obtient un problème d'optimisation sans contrainte. (Madallah Al – Ruwaili, Mohammed Hamid Siddiqi. (2020))

II.2.1. moyennes possibilistes (Ma, Q., Zhu, X., Zhao, X., Fu, G., Zhang, R. 2024)

$$J_m(U, V) = \sum_{j=1}^c \sum_{i=1}^n u_{ji}^m d^2(x_i, g_j) + \sum_{j=1}^c \eta_i \sum_{i=1}^n (1 - u_{ji})^m \quad (10)$$

La minimisation de la fonction objective est réalisée par le processus itératif tel que décrit dans l'algorithme FCM.

$$\frac{\partial J_m^{ji}}{\partial \mu_{ji}} = m \mu_{ji}^{m-1} d^2(x_i, g_j) - m \eta_i (1 - \mu_{ji})^{m-1} = 0. \quad (11)$$

De cette relation (11), nous déduisons :

$$\mu_{ik} = \frac{1}{1 + \left(\frac{d^2}{\eta_i} \right)^{\frac{1}{m-1}}} \quad (12)$$

Le paramètre η_i contrôle la décroissance de la fonction d'appartenance à la classe c_i . (S. Askari 2021)

Le paramètre m représente le niveau de flou de l'algorithme.

Lorsque $m \rightarrow 1$ l'exposant $\frac{1}{m-1}$ tend vers l'infini, et le degré d'appartenance devient binaire, 1 si la distance de x_k au centre est inférieure à η_i et zéro dans le cas contraire.

Avec η_i la moyenne de la distance floue aux centroïdes : $\eta_i = \frac{\sum_{k=1}^n \mu_{ik}^m d^2(x_k, v_i)}{\sum_{k=1}^n \mu_{ik}^m}$ (13)

La formule (13) donne l'estimation de η_i en début du programme. (H. Verma et al. (2021))

Ces paramètres sont affinés, si on le désire, après un premier passage du programme, à l'aide de la partition ainsi obtenue en faisant appel à des coupes de niveau α , α étant choisi pour se limiter aux éléments centraux de la classe i .

$$\eta_i = \frac{\sum_{x_j \in \pi_i(\alpha)} d_{ij}^2}{|\pi_i(\alpha)|} \quad (14)$$

Algorithme

Choisir les valeurs de c et de m

Initialiser la partition

Calculer les η_i par la formule

Le paramètre η_i est estimé au début du programme par

$$\eta_i = \frac{\sum_{j=1}^n u_{ij}^m d_{ij}^2}{\sum_{j=1}^n u_{ij}^m}$$

Ces paramètres sont affinés, si on le désire, après un premier passage du programme, à l'aide de la partition ainsi obtenue en faisant appel à des coupes de niveau α étant choisi pour se limiter aux éléments centraux de la classe i dans le calcul de η_i

$$\eta_i = \frac{\sum_{x_j \in \pi_i(\alpha)} d_{ij}^2}{|\pi_i(\alpha)|}$$

$\pi_i(\alpha)$ étant la coupe du groupe i de niveau α et $|\pi_i(\alpha)|$ le cardinal de cette coupe

Initialiser le compteur d'itération $t = 1$

Répéter

Calculez le centre à l'aide de la matrice $U^{(t)}$ par

$$c_i^{(t)} = \frac{\sum_{j=1}^n (u_{ij}^{(t)})^m x_j}{\sum_{j=1}^n (u_{ij}^{(t)})^m}$$

Calculer la nouvelle matrice $U^{(t+1)}$ à l'aide de la formule

$$u_{ij} = \frac{1}{1 + \left(\frac{d_{ij}^2}{\eta_i} \right)^{\frac{1}{m-1}}}$$

Incrémenter le compteur d'itération

II.3. Agglomération compétitive : régulation de la fonction cout.

Objectif : Introduire une composante de régularisation dans la fonction cout, permettant de ne pas fixer à priori le nombre de groupes.

Le fonctionnelle à minimiser :

$$J(M) = \sum_{j=1}^k \sum_{i=1}^n \mu_{ij}^2 d^2(x_i, m_j) - \beta \sum_{j=1}^k (\sum_{i=1}^n \mu_{ij})^2 \quad (15)$$

$\beta > 0$ étant un paramètre qui décroît de façon exponentielle au fil d'itérations (engendre une compétition entre les groupes).

Les degrés d'appartenance sont actualisés suivants :

$$\mu_{ij} = \frac{\frac{1}{d^2(x_i, m_j)}}{\sum_{q=1}^k \frac{1}{d^2(x_i, m_q)}} + \frac{\beta}{d^2(x_i, m_j)} \left[N_j - \frac{\sum_{q=1}^k \frac{N_q}{d^2(x_i, m_q)}}{\sum_{q=1}^k \frac{1}{d^2(x_i, m_q)}} \right] \quad (16)$$

II.3.1. Algorithme d'agglomération compétitive (Zhang, Y., Li, Y., Che, J. 2024)

1. Initialisation aléatoire de centres (dans le domaine couvert par les n individus)

Répéter

Calcul β pour l'itération courante ;

Calcul du centre de gravité de l'ensemble d'individus d'un même groupe et remplacement des anciens centres par les nouveaux ;

Calcul de l'effectif flou et élimination des groupes dont l'effectif est inférieur à un seuil ;

Tant que les centres ne sont pas stabilisés

Chaque groupe contient l'ensemble des individus les plus proches d'un centre.

Les effectifs flous de groupes, N_j , sont donnés par $N_j = \sum_{i=1}^n \mu_{ij}$ (avec $\sum_{k=1}^n N_j = n$) et l'évolution de β au fil des itérations t est :

$$\beta(t) = n_0 e^{-\frac{t}{\tau} \frac{\sum_{j=1}^k \sum_{i=1}^n \mu_{ij}^2 d^2(x_i, m_j)}{\sum_{j=1}^k (\sum_{i=1}^n \mu_{ij})^2}} \quad (17)$$

Suite à la compétition, les groupes dont l'effectif flou devient inférieur à un seuil (en général très bas) sont éliminés, ainsi que leurs centres.

Le paramètre nombre de groupe k difficile à choisir est remplacé par la valeur initiale et la vitesse de décroissance de β , auxquelles l'algorithme est moins sensible.

III. EXPÉRIMENTATION ET INTERPRÉTATION DE RÉSULTATS

Notre étude porte sur la segmentation de patients atteints de syndrome métabolique.

III.1. Syndrome métabolique (Sitraka Angelo Rahinavalona et al. 2020)

Le **syndrome métabolique** désigné par les acronymes *SMet* (pour *syndrome métabolique*) ou *MetS* (pour *Metabolic syndrome* chez les anglophones) désigne l'association d'une série de problèmes de santé ayant en commun un mauvais métabolisme corporel.

Le *syndrome métabolique* regroupe dans sa définition la présence de plusieurs anomalies métaboliques associées (obésité abdominale, hypertriglycéridémie, HDL-cholestérol bas, intolérance au glucose ou diabète de type 2, hypertension).

Tableau2 : Définition du syndrome métabolique selon l'organisation mondiale de la santé

Présence de diabète ou d'intolérance au glucose ou résistance à l'insuline et deux des paramètres suivants	
Paramètre	Critère diagnostic
Hypertension artérielle	> 160mmHg (systolique) ou > 90mmHg (diastolique)
Dyslipidémie	TG : 1,7mmol/L ou HDL : < 0,9mmol/L chez les hommes et < 1 mmol/L chez les femmes.

Obésité	IMC : $30\text{kg}/\text{m}^2$ >0,9 chez les hommes >0,85 chez les femmes
Micro albuminurie	$20\mu\text{g}/\text{min}$

Dans notre étude nous avons considéré la présence de diabète, IMC, et l'hypertension artérielle.

III.2. Implémentation et interprétation des résultats

Nous avons développé notre application en Csharp qui est un

langage de programmation objet. Cette application permet à l'utilisateur d'importer son data set à partir d'Excel et les analyser afin d'obtenir des classes hypogènes après la défuzzification.

Interface de saisie

Cette interphase permet de saisir les données de votre data set ou de l'importer à partir d'un fichier Excel. Le data set utilisé, concerne les patients du Centre Hospitalier du Mont-Amba (en République Démocratique du Congo)




Figure 3. Interface de saisie

Le tableau suivant est la matrice floue finale qui détermine le degré d'appartenance des individus aux différents sous-ensembles flous obtenus à l'aide de notre programme. Nous

avons donné à titre illustratif les cas de quatorze premiers individus.

Tableau 3 : Matrice floue de degré d'appartenance

L1	L2	L3	L4	L5	L6	L7
0,10879203	0,79001455	0,87342563	0,98002185	0,33938769	0,33743646	0,17011043
0,42510033	0,04312819	0,07848955	0,01527399	0,27999022	0,02125579	0,55671751
0,45761496	0,03262103	0,0200969	0,00457742	0,0398841	0,59806818	0,11377382
0,00604597	0,0106532	0,00340763	0,00012486	0,17452478	0,03702935	0,01494851
0,00242432	0,06413184	0,01204606	1,83E-06	0,03939716	0,00030187	0,13917178
2,239E-05	0,05945119	0,01253423	5E-08	0,12681605	0,00590835	0,00527795
L8	L9	L10	L11	L12	L13	L14
0,38176374	0,53352106	0,28023994	0,21948822	0,39412245	0,09329773	0,11051635
0,24538041	0,23420186	0,46768165	0,56151989	0,08229401	0,04519848	0,06458063
0,35066247	0,09828886	0,17525584	0,08480136	0,42432807	0,59288295	0,16135177
0,00443441	0,09823958	0,0414168	0,10364562	0,06827355	0,14096433	0,15620963
0,01224502	0,03152305	0,0276187	0,01725486	0,02688235	0,1024262	0,31928722
0,00551395	0,00422559	0,00778707	0,01329005	0,00409956	0,0252303	0,18805439

Après defuzzification, nous obtenons le graphique suivant :




Figure 4. Histogramme après défuzzification

En vertu des résultats obtenus nous dégageons les règles floues suivantes :

R1 : Si l'indice de masse corporel est élevé et la glycémie est élevée, la tension systolique est élevée, l'âge est avancé alors l'individu appartient à la classe **C1**.

R2 : Si l'indice de masse corporel est un peu élevé et la tension est moyenne et l'âge est avancé et la glycémie est un peu élevée alors l'individu appartient à la classe **C2**.

R3 : Si l'indice de masse corporel est élevé et la tension est moyenne et l'âge est avancé et la glycémie est assez élevée alors l'individu appartient à la classe **C3**.

R4 : Si l'indice de masse corporel est normal et la tension est moyenne et l'âge est avancé et la glycémie est un peu élevée alors l'individu appartient à la classe **C4**.

R5 : Si l'indice de masse corporel est légèrement au-dessus du niveau normal et la tension est un peu élevé et l'âge est avancé et la glycémie est normale alors l'individu appartient à la classe **C5**.

R6 : Si l'indice de masse corporel est normal et la tension est normale et l'âge est avancé et la glycémie est très élevée alors l'individu appartient à la classe **C6**.

En vertu de ces règles, nous constatons que la classe C1 est constituée des individus susceptibles de développer le syndrome métabolique.

La combinaison de FCM et l'approche possibiliste présente beaucoup d'avantage que l'utilisation de FCM seul. Nous avons obtenu le même nombre de classes avec la méthode d'agglomération compétitive. Notre approche présente des très bons résultats, les classes sont compactes. Notre approche présente aussi un avantage en ce qui concerne la prise en charge de personnes souffrant du syndrome métabolique, car elle permet au médecin de se focaliser sur plusieurs facteurs car un même patient appartient à plusieurs classes, d'où le personnel soignant ne va pas se concentrer seulement sur les caractéristiques d'une seule classe il va plutôt explorer d'autres classes selon le degré d'appartenance du patient pour un traitement efficace.

Comme perspective d'avenir il serait mieux de créer un classifieur flou qui est un réseau de neurone flou hybride, c'est-à-dire un modèle de réseau de neurones qui combine dans une architecture homogène, la logique flou et le réseau de neurones. Un classifieur flou est un système flou $F_R : X \rightarrow Y$ où $X \subseteq$

$\mathbb{R}^n$ et $Y = [0,1]^m$. $\mathcal{R}$ est une base de règle floues à partir de laquelle on déterminera la règle floue de la forme

$R_k = (\mu_k^{(1)}, \dots, \mu_k^{(n)}, C_{jk})$ où $C_{jk} \in C = \{C_1, \dots, C_n\}$ qui est l'ensemble d'étiquettes de classes

CONCLUSION

Dans Cet article, nous avons exploité une approche floue pour la segmentation de données. Ceci se justifie par le fait que la plupart des méthodes de classification donne des mauvais résultats lorsqu'on est en présence de données incertaines. Nous avons développé une techniques hybrides basée sur l'utilisation successive de FCM et l'approche possibiliste. Nous avons exploité l'agglomération compétitive, nous avons trouvé le même nombre de classes. Nous avons utilisé la logique floue pour prendre en compte le traitement des connaissances imprécises, afin de traiter des données complexes dans lesquelles sont, présentes des variables linguistiques non mesurables. Comme perspective d'avenir, nous proposons la création d'un classifieur neuronal flou pour la prédiction des nouvelles instances.

REFERENCES

- [1] Kaur, A., Kumar, Y., Sidhu, J. (2024). Exploring meta-heuristics for partitional clustering: methods, metrics, datasets, and challenges. Artificial Intelligence Review.
- [2] Oskouei, A.G., Samadi, N., Tanha, J., Bouyer, A. (2024). Semi-Supervised Fuzzy C-Means method based on Feature-Weight and Cluster-Weight learning
- [3] Shukla, A.K., Behera, S.K., Basumatary, A., Shukla, V. (2024), Datta, S.P. PCA and fuzzy clustering-based delineation of soil nutrient (S, B, Zn, Mn, Fe, and Cu) management zones of sub-tropical Northeastern India for precision nutrient management, Software Impacts
- [4] Ros, F., Riad, R.A. (2024) deep learning-based Clustering solution without any clustering algorithm, Utopia? Knowledge-Based Systems
- [5] Wan, F., Wang, T., Fondrevelle, J., Duclos, A. (2024). Collaborative optimization of surgery and ICU under uncertainty. Expert Systems with Applications
- [6] Sahoo, R.C., Kumar, T., Tanwar, P., Pruthi, J., Singh, S. (2024). An efficient meta-heuristic algorithm based

- on water flow optimizer for data clustering An efficient meta-heuristic for data clustering. *Journal of Supercomputing*
- [7] Bhimavarapu, U., Chintalapudi, N., Battineni, G. (2024). Brain Tumor Detection and Categorization with Segmentation of Improved Unsupervised Clustering Approach and Machine Learning Classifier
 - [8] Chan, K.Y., Yiu, K.F.C., Kim, D., Abu-Siada, A. (2024). Fuzzy Clustering-Based Deep Learning for Short-Term Load Forecasting in Power Grid Systems. *Sensors*
 - [9] Ma, Q., Zhu, X., Zhao, X., Fu, G., Zhang, R. (2024) An equidistance index intuitionistic fuzzy c-means clustering algorithm based on local density and membership degree boundary. *Applied Intelligence*
 - [10] Zhang, Y., Li, Y., Che, J. (2024) Optimal weight random forest ensemble with Fuzzy C-means cluster-based subsampling for carbon price forecasting. *Journal of Intelligent and Fuzzy Systems*
 - [11] Madallah Al – Ruwaili, Mohammed Hamid Siddiqi. (2020). Mohammed Arshad Javed. A robust clustering algorithm using spatial fuzzy C-means for brain MR images *Egyptian Informatics Journal*
 - [12] S. Askari (2021). Review and development: Fuzzy C-Means clustering algorithm for data with unequal cluster sizes and contaminated with noise and outliers. *Expert Systems with Applications*
 - [13] M. Shi *et al.* (2020) A fuzzy c-means algorithm based on the relationship among attributes of data and its application in tunnel boring machine. *Knowledge-Based Systems*
 - [14] H. Verma *et al.* (2021). A population based hybrid FCM-PSO algorithm for clustering analysis and segmentation of brain image *Expert Systems with Applications*
 - [15] Sitraka Angelo Rahinavalona et all. (2020) Prévalence du syndrome métabolique et des facteurs de risque cardiovasculaire chez les diabétiques de type 2, *Pan African Medical Journal*